

ỦY BAN NHÂN DÂN
THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN



**BÁO CÁO TỔNG KẾT
ĐỀ TÀI NGHIÊN CỨU KHOA HỌC
CỦA SINH VIÊN**

TÊN ĐỀ TÀI:

**XÂY DỰNG MÔ HÌNH PHÁT HIỆN GIAN LẬN TÀI CHÍNH
MINH BẠCH DỰA TRÊN EXPLAINABLE AI**

Mã số đề tài: SVA2025- 001

Thuộc nhóm ngành khoa học: Kỹ thuật

Chủ nhiệm đề tài: Tạ Trần Tuyền

Thành viên tham gia: Tạ Trần Tuyền

Giảng viên hướng dẫn: TS. Nguyễn Quốc Huy

ỦY BAN NHÂN DÂN
THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN

BÁO CÁO TỔNG KẾT
ĐỀ TÀI NGHIÊN CỨU KHOA HỌC CỦA SINH VIÊN

TÊN ĐỀ TÀI:
XÂY DỰNG MÔ HÌNH PHÁT HIỆN GIAN LẬN TÀI CHÍNH
MINH BẠCH DỰA TRÊN EXPLAINABLE AI
Mã số đề tài: SVA2025-001

Xác nhận của Khoa

(ký, họ tên)

Giáo viên hướng dẫn

(ký, họ tên)

Chủ nhiệm đề tài

(ký, họ tên)

MỤC LỤC

DANH MỤC CÁC CHỮ VIẾT TẮT	i
DANH MỤC HÌNH	ii
DANH MỤC BẢNG	iii
MỞ ĐẦU	1
CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI	8
1.1 Nhu cầu thực tế	8
1.2 Các phương pháp phát hiện gian lận tài chính	9
1.3 Tổng quan về Trí tuệ nhân tạo giải thích được (XAI)	9
1.4 Vấn đề nghiên cứu và mục tiêu của đề tài	10
1.5 Ý nghĩa khoa học và thực tiễn	10
1.6 Đối tượng và phạm vi nghiên cứu	11
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ PHƯƠNG PHÁP NGHIÊN CỨU	12
2.1 Bài toán Phát hiện Gian lận: Từ Góc nhìn Thống kê đến Học máy	12
2.1.1 Sự giới hạn của các Mô hình Tuyến tính	12
2.2 Lý thuyết Học Kết hợp (Ensemble Learning) và Boosting	12
2.3 Bước tiến của Học Sâu: Kiến trúc và Toán học trong TabNet	13
2.4 Hình học không gian mẫu: Vượt qua rào cản Mất cân bằng (SMOTE) .	14
2.5 Trí tuệ Nhân tạo Giải thích được (XAI): Chìa khóa của sự Tin cậy . . .	15
2.6 Phương pháp Nghiên cứu (Research Methodology)	15

CHƯƠNG 3: QUY TRÌNH THỰC NGHIỆM VÀ XÂY DỰNG MÔ HÌNH	18
3.1 Thu thập và Phân tích Tập dữ liệu Thực nghiệm (EDA)	18
3.1.1 Tập dữ liệu MLG-ULB (Châu Âu)	18
3.1.2 Tập dữ liệu IEEE-CIS Fraud Detection	18
3.1.3 Tập dữ liệu Sparkov (Dữ liệu tổng hợp)	19
3.2 Kỹ thuật Tiền xử lý và Làm sạch Dữ liệu (Data Preprocessing)	19
3.2.1 Xử lý Dữ liệu Khuyết (Missing Value Imputation)	19
3.2.2 Chuẩn hóa (Feature Scaling) và Mã hóa (Encoding)	20
3.2.3 Xử lý Mất cân bằng Lớp bằng thuật toán SMOTE	20
3.3 Thiết lập Kiến trúc Mô hình và Môi trường Thực nghiệm	21
3.3.1 Thiết lập các Mô hình Nền tảng (Baseline Models)	21
3.3.2 Thiết lập Kiến trúc Học sâu TabNet	21
3.4 Chiến lược Đánh giá và Các Chỉ số Hiệu suất	21
CHƯƠNG 4: TRIỂN KHAI VÀ TÍCH HỢP CÁC KỸ THUẬT XAI	23
4.1 Lựa chọn Kỹ thuật XAI cho Dữ liệu Tài chính dạng Bảng	23
4.2 Tích hợp XAI: Xây dựng Cầu nối từ Cục bộ đến Toàn cục	23
4.2.1 Cấp độ Cục bộ (Local Explanations): Phân tích Từng Giao dịch	24
4.2.2 Cấp độ Toàn cục (Global Explanations): Thấu hiểu Hành vi Hệ thống	24
4.3 Giải quyết Thách thức Kỹ thuật và Tối ưu hóa Trực quan hóa	24
4.3.1 Bài toán Hiệu suất: Nút thắt Tính toán của SHAP	25
4.3.2 Tối ưu hóa Giao diện và Khả năng Đọc hiểu (Readability) . . .	26
CHƯƠNG 5: THỰC NGHIỆM, ĐÁNH GIÁ VÀ PHÂN TÍCH KẾT QUẢ	27
5.1 Đánh giá và so sánh hiệu suất các mô hình trên các tập dữ liệu	27

5.1.1	Kết quả trên tập dữ liệu MLG-ULB	27
5.1.2	Kết quả trên tập dữ liệu Sparkov	28
5.1.3	Kết quả trên tập dữ liệu IEEE-CIS	29
5.2	Thiết kế kịch bản thí nghiệm đánh giá chất lượng giải thích XAI	31
5.3	Phân tích và So sánh các kỹ thuật XAI trên mô hình TabNet	31
5.3.1	Kết quả giải thích trên tập dữ liệu MLG-ULB	31
5.3.2	Kết quả giải thích trên tập dữ liệu Sparkov	32
5.3.3	Kết quả giải thích trên tập dữ liệu IEEE-CIS	34
5.4	Khảo sát người dùng và Tính ứng dụng thực tế	34
CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN TƯƠNG LAI		36
6.1	Tổng hợp kết quả đạt được và Ý nghĩa thực tiễn	36
6.2	Đề xuất hướng phát triển và Tầm nhìn tương lai	37
TÀI LIỆU THAM KHẢO		39

DANH MỤC CÁC CHỮ VIẾT TẮT

DiCE	Diverse Counterfactual Explanations
DL	Deep Learning
FN	False Negative
FP	False Positive
GLU	Gated Linear Unit
LIME	Local Interpretable Model-agnostic Explanations
ML	Machine Learning
PCA	Principal Component Analysis
SHAP	SHapley Additive exPlanations
SMOTE	Synthetic Minority Oversampling Technique
TN	True Negative
TP	True Positive
XAI	Explainable Artificial Intelligence

DANH MỤC HÌNH

Hình 1.1	Thống kê và dự báo thiệt hại do gian lận thẻ toàn cầu theo báo cáo Nilson	8
Hình 2.1	Quy trình tối ưu hóa lỗi tuần tự trong Gradient Boosting	13
Hình 2.2	Kiến trúc tổng thể của mô hình TabNet (TabNet Model Architecture)	13
Hình 2.3	Biểu diễn hình học của kỹ thuật nội suy SMOTE trong không gian đặc trưng	15
Hình 2.4	Sơ đồ quy trình nghiên cứu hệ thống 4 giai đoạn	16
Hình 4.1	Kiến trúc Tích hợp Kỹ thuật XAI đa cấp độ vào Hệ thống Phát hiện Gian lận	25
Hình 5.1	Giải thích cục bộ bằng LIME trên tập dữ liệu MLG-ULB	32
Hình 5.2	Đánh giá tầm quan trọng đặc trưng bằng SHAP trên tập dữ liệu MLG-ULB	32
Hình 5.3	Giải thích cục bộ bằng LIME trên tập dữ liệu Sparkov	33
Hình 5.4	Đánh giá tầm quan trọng đặc trưng bằng SHAP trên tập dữ liệu Sparkov	33
Hình 5.5	Kịch bản thay đổi phản thực tế DiCE trên tập dữ liệu Sparkov . . .	33
Hình 5.6	Giải thích cục bộ bằng LIME trên tập dữ liệu IEEE-CIS	34
Hình 5.7	Đánh giá tầm quan trọng đặc trưng bằng SHAP trên tập dữ liệu IEEE-CIS	34

DANH MỤC BẢNG

Bảng 5.1	Kết quả đánh giá hiệu suất các mô hình trên tập dữ liệu MLG-ULB	28
Bảng 5.2	Kết quả đánh giá hiệu suất các mô hình trên tập dữ liệu Sparkov	29
Bảng 5.3	Kết quả đánh giá hiệu suất các mô hình trên tập dữ liệu IEEE-CIS	30

BẢN TÓM TẮT ĐỀ TÀI

Trong bối cảnh công nghệ tài chính (Fintech) và thanh toán không dùng tiền mặt phát triển mạnh mẽ, giao dịch qua thẻ tín dụng đã mang lại sự tiện lợi to lớn cho nền kinh tế toàn cầu. Tuy nhiên, sự gia tăng về khối lượng giao dịch số cũng kéo theo sự bùng nổ của các hành vi gian lận tài chính ngày càng tinh vi và phức tạp. Các hệ thống cảnh báo dựa trên quy tắc truyền thống (rule-based) hoặc các mô hình học máy tuyến tính đang dần bộc lộ những hạn chế trong việc xử lý dữ liệu lớn, tính phi tuyến tính cao và đặc tính mất cân bằng cực đoan của tội phạm tài chính.

Để giải quyết thách thức này, nghiên cứu đề xuất một hệ thống phát hiện gian lận thẻ tín dụng toàn diện dựa trên kiến trúc học sâu tiên tiến TabNet – một mạng nơ-ron được thiết kế chuyên biệt để trích xuất đặc trưng trên dữ liệu dạng bảng thông qua cơ chế chú ý tuần tự (Sequential Attention). Để khắc phục vấn đề mất cân bằng dữ liệu, kỹ thuật nội suy không gian mẫu SMOTE (Synthetic Minority Oversampling Technique) được áp dụng nhằm tối ưu hóa ranh giới quyết định của mô hình.

Quá trình thực nghiệm được triển khai nghiêm ngặt trên ba bộ dữ liệu mang tính đại diện cao: MLG-ULB (dữ liệu Châu Âu ẩn danh), Sparkov (dữ liệu tổng hợp) và IEEE-CIS (dữ liệu thương mại điện tử thực tế). Kết quả đánh giá chỉ ra rằng TabNet vượt trội so với các thuật toán học máy truyền thống và học kết hợp (Ensemble Learning), đạt điểm F1-Score ấn tượng ở mức 0.8421 đối với tập MLG-ULB, 0.9387 trên tập IEEE-CIS, và chạm ngưỡng 0.9841 với tập Sparkov, đồng thời duy trì khả năng nhận diện (Recall) lên tới 0.9918.

Không dừng lại ở việc tối ưu hóa hiệu suất dự đoán, nghiên cứu còn giải quyết một rào cản lớn nhất của mạng học sâu trong lĩnh vực tài chính: sự thiếu hụt tính minh bạch (Black-box problem). Thông qua việc tích hợp hệ sinh thái Trí tuệ Nhân tạo Giải thích được (Explainable AI - XAI) bao gồm cấu trúc giải thích nội tại của TabNet, kết hợp cùng SHAP, LIME và phân tích phản thực tế DiCE, hệ thống có khả năng xuất ra các diễn giải định lượng, logic và trực quan cho từng quyết định khóa thẻ.

Khảo sát thực tiễn cho thấy việc áp dụng XAI không chỉ giúp các chuyên gia quản

trị rủi ro giảm thiểu thời gian điều tra các cảnh báo nhầm (False Positives), mà còn gia tăng sự tin cậy vào hệ thống tự động. Đề tài đóng góp một khung giải pháp trọn vẹn: vừa đảm bảo khả năng phòng thủ mạnh mẽ trước tội phạm tài chính, vừa đáp ứng nghiêm ngặt các tiêu chuẩn về tính minh bạch và trách nhiệm giải trình của ngành ngân hàng hiện đại.

Từ khóa: Phát hiện gian lận thẻ tín dụng (Credit Card Fraud Detection), TabNet, Học sâu trên dữ liệu dạng bảng (Deep Learning on Tabular Data), SMOTE, Trí tuệ nhân tạo giải thích được (Explainable AI - XAI).

MỞ ĐẦU

1. Lý do chọn đề tài

Trong bối cảnh chuyển đổi số đang diễn ra mạnh mẽ, các hành vi gian lận tài chính ngày càng trở nên tinh vi, phức tạp và khó kiểm soát. Điều này đặt ra yêu cầu cấp thiết về việc xây dựng các hệ thống phát hiện gian lận tự động có độ chính xác cao để bảo vệ tính toàn vẹn của hệ thống tài chính.

Mặc dù nhiều mô hình học máy và học sâu hiện đại đã được ứng dụng hiệu quả trong việc nhận diện các giao dịch bất thường, phần lớn các mô hình này vẫn hoạt động theo cơ chế "hộp đen" (black-box). Việc thiếu khả năng giải thích khiến người dùng và các chuyên gia khó có thể lý giải tại sao một quyết định cụ thể lại được đưa ra. Trong lĩnh vực tài chính — nơi yêu cầu khắt khe về tính minh bạch, kiểm toán và tuân thủ pháp lý — sự thiếu hụt này gây ra nhiều trở ngại cho việc triển khai AI một cách có trách nhiệm.

Tại Việt Nam, các nghiên cứu về phát hiện gian lận tài chính chủ yếu vẫn tập trung vào các mô hình truyền thống như ANN hay SVM nhằm cải thiện độ chính xác, nhưng chưa thực sự chú trọng đến tính giải thích của mô hình. Trong khi đó, trên thế giới, trí tuệ nhân tạo giải thích được (Explainable AI - XAI) đang dần trở thành một tiêu chuẩn không thể thiếu để xây dựng niềm tin giữa con người và hệ thống AI. Các kỹ thuật như SHAP, LIME, hay DiCE đã chứng minh được hiệu quả trong việc làm minh bạch hóa các dự đoán phức tạp.

2. Lịch sử nghiên cứu vấn đề

Các nghiên cứu trong nước

Tại Việt Nam, nghiên cứu ứng dụng trí tuệ nhân tạo trong phát hiện gian lận tài chính đã được một số nhóm thực hiện, tuy nhiên phần lớn vẫn tập trung vào việc áp dụng các mô hình học máy truyền thống như mạng nơ-ron nhân tạo (ANN) và máy vector hỗ trợ (SVM), với mục tiêu cải thiện độ chính xác dự đoán. Một ví dụ tiêu biểu là nghiên cứu gần đây của Phong và cộng sự, trong đó sử dụng các mô hình học máy để nhận diện gian lận trong báo cáo tài chính các doanh nghiệp niêm yết trên thị trường Việt Nam.

Mặc dù cho kết quả khá khả quan, nghiên cứu này chưa đề cập đến tính giải thích của mô hình, điều vốn rất quan trọng trong bối cảnh các quy định pháp lý và yêu cầu minh bạch ngày càng được chú trọng.

Hầu hết các công trình trong nước hiện nay chưa khai thác các kỹ thuật Explainable AI (XAI), khiến người dùng khó hiểu hoặc không thể lý giải các quyết định mà mô hình đưa ra. Điều này tạo ra khoảng trống nghiên cứu lớn, đặc biệt là trong bối cảnh yêu cầu minh bạch trong tài chính ngày càng cao. Việc kết hợp giữa phát hiện gian lận và khả năng giải thích là một hướng nghiên cứu mới, có tiềm năng đóng góp thiết thực cho cả lĩnh vực học thuật và thực tiễn.

Các nghiên cứu quốc tế

Trên thế giới, lĩnh vực XAI đã có sự phát triển mạnh mẽ trong hơn một thập kỷ qua, đặc biệt là trong các ngành đòi hỏi tính minh bạch và kiểm soát rủi ro cao như tài chính, ngân hàng và y tế. Các nghiên cứu nền tảng như SHAP và LIME đã mở ra những cách tiếp cận mới để giải thích các mô hình học máy phức tạp một cách rõ ràng, dễ hiểu cho cả nhà phát triển lẫn người sử dụng cuối. Ngoài ra, các kỹ thuật như Anchor hay phương pháp giải thích toàn cục đối với cây quyết định đã giúp cải thiện tính tin cậy của các mô hình học sâu trong thực tiễn.

Bên cạnh đó, một số công trình tổng quan như của Arrieta et al. và Adadi & Berrada đã hệ thống hóa toàn bộ lĩnh vực Explainable AI, từ phân loại kỹ thuật đến các tiêu chí đánh giá hiệu quả giải thích, qua đó tạo nền tảng vững chắc cho việc triển khai XAI một cách có trách nhiệm.

Trong lĩnh vực phát hiện gian lận tài chính, XAI ngày càng chứng minh được vai trò quan trọng. Gần đây, các nhà nghiên cứu đã đề xuất nhiều giải pháp kết hợp XAI với các mô hình học sâu trong phát hiện gian lận thời gian thực tại ngân hàng, xây dựng khung giải thích hướng người dùng, cũng như triển khai các hệ thống dựa trên SHAP và học tổ hợp để phát hiện gian lận thẻ tín dụng với hiệu quả cao. Những công trình này không chỉ nâng cao độ chính xác mà còn đảm bảo khả năng kiểm tra, truy vết và hiểu được lý do đằng sau các dự đoán.

Tổng kết lại, trong khi các công trình quốc tế đã đạt được nhiều tiến bộ trong việc

tích hợp XAI vào phát hiện gian lận tài chính, thì ở Việt Nam lĩnh vực này vẫn còn thiếu vắng các nghiên cứu hệ thống. Đây chính là cơ hội và động lực cho các đề tài như hiện tại, nhằm thu hẹp khoảng cách về mặt nghiên cứu, đồng thời cung cấp giải pháp thiết thực cho các tổ chức tài chính trong nước.

3. Mục đích và nhiệm vụ nghiên cứu

Mục tiêu chung: Đề tài hướng đến xây dựng một hệ thống trí tuệ nhân tạo giải thích được (XAI) để phát hiện gian lận tài chính. Hệ thống không chỉ đảm bảo độ chính xác cao trong nhận diện các giao dịch bất thường, mà còn có khả năng cung cấp lời giải thích rõ ràng, giúp người dùng hiểu và tin tưởng vào kết quả. Qua đó, đề tài góp phần tăng cường tính minh bạch, hỗ trợ ra quyết định, và đáp ứng yêu cầu pháp lý trong lĩnh vực tài chính – ngân hàng.

Mục tiêu cụ thể:

- Xây dựng nền tảng lý thuyết: Phân tích và phân loại các kỹ thuật XAI như SHAP, LIME; xây dựng tiêu chí đánh giá chất lượng giải thích dựa trên độ chính xác, tính ổn định và khả năng hiểu của người dùng.
- Phát triển mô hình và thuật toán: Thiết kế các thuật toán phát hiện gian lận được tối ưu hóa cho dữ liệu mất cân bằng và khối lượng lớn, đồng thời tích hợp nhiều kỹ thuật XAI để cung cấp giải thích toàn diện.
- Thực nghiệm và đánh giá: Tiến hành kiểm thử trên nhiều bộ dữ liệu thực tế, so sánh các phương pháp về độ chính xác và chất lượng giải thích, đồng thời đánh giá tính ổn định trước thay đổi và tấn công.

Kết quả kỳ vọng: Đề tài tạo ra một hệ thống AI vừa thông minh, vừa minh bạch, có khả năng triển khai trong thực tế, đồng thời mang lại đóng góp khoa học có giá trị cho lĩnh vực AI và tài chính – ngân hàng.

4. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu: Đề tài tập trung vào các kỹ thuật và phương pháp luận cốt lõi của trí tuệ nhân tạo giải thích được (XAI), đặc biệt là cách tích hợp và vận hành chúng trong các mô hình học máy và học sâu để phát hiện gian lận tài chính. Nghiên cứu

sẽ phân tích các thuật toán như LIME, SHAP, cơ chế Attention, và giải thích phản thực tế, đồng thời khảo sát mối liên hệ giữa khả năng giải thích và hiệu quả dự đoán. Ngoài ra, đối tượng còn bao gồm các mô hình AI dùng để phát hiện gian lận và bộ dữ liệu giao dịch tài chính (gồm giao dịch hợp lệ và gian lận) phục vụ huấn luyện và kiểm thử.

Phạm vi nghiên cứu: Về lý thuyết, đề tài tập trung vào các phương pháp XAI phù hợp với dữ liệu tài chính dạng bảng và chuỗi thời gian, cùng hệ thống tiêu chí đánh giá chất lượng giải thích. Về thực nghiệm, nghiên cứu giới hạn trong một số loại gian lận phổ biến như gian lận thẻ tín dụng hoặc thanh toán trực tuyến, tùy thuộc vào dữ liệu thu thập được. Đề tài sẽ triển khai, so sánh hiệu quả các kỹ thuật XAI trên mô hình học máy cụ thể, hướng tới xây dựng một khung thử nghiệm tích hợp XAI. Dữ liệu sử dụng ưu tiên các tập công khai, chuẩn hóa hoặc dữ liệu thực tế đã ẩn danh; toàn bộ triển khai sử dụng công cụ và thư viện mã nguồn mở.

5. Phương pháp nghiên cứu

Cách tiếp cận: Đề tài áp dụng phương pháp nghiên cứu kết hợp giữa lý thuyết và thực nghiệm. Mục tiêu là phát triển và đánh giá các mô hình phát hiện gian lận tài chính tích hợp kỹ thuật giải thích (XAI). Dữ liệu sẽ được xử lý và phân tích theo quy trình chuẩn để đảm bảo đầu vào phù hợp cho các mô hình học máy.

Tiền xử lý và chọn đặc trưng: Dữ liệu sẽ được khám phá ban đầu, xử lý giá trị thiếu, chuẩn hóa các biến số (dùng StandardScaler), và mã hóa biến phân loại. Ma trận tương quan được sử dụng để chọn đặc trưng phù hợp với biến mục tiêu, nhằm nâng cao hiệu quả dự đoán.

Nguồn dữ liệu: Nghiên cứu ưu tiên sử dụng các bộ dữ liệu công khai từ Kaggle, UCI hoặc tổ chức nghiên cứu (ví dụ: Credit Card Fraud Detection). Trong trường hợp cần mở rộng, có thể tạo dữ liệu tổng hợp (synthetic) hoặc khai thác dữ liệu thực tế từ tổ chức tài chính theo thỏa thuận NDA và yêu cầu ẩn danh hóa.

Quy trình thực nghiệm:

- Giai đoạn 1: Xây dựng mô hình nền tảng Triển khai các mô hình như Logistic Regression, Random Forest, Gradient Boosting, Neural Networks, LSTM trên tập dữ liệu đã xử lý. Đánh giá bằng các chỉ số Accuracy, Precision, Recall, F1-score,

AUC-ROC/PR.

- Giai đoạn 2: Tích hợp XAI Áp dụng các kỹ thuật XAI như SHAP, LIME để giải thích đầu ra của mô hình. Lựa chọn kỹ thuật phù hợp với từng loại dữ liệu và mô hình.
- Giai đoạn 3: Đánh giá lời giải thích Đánh giá các giải thích XAI theo độ trung thực (fidelity), ổn định (robustness) và độ phức tạp/dễ hiểu (complexity). Có thể khảo sát người dùng (chuyên gia hoặc sinh viên tài chính/AI) để đánh giá khả năng hiểu và tính hữu ích.
- Giai đoạn 4: So sánh và đề xuất So sánh hiệu quả và tính thực tiễn của các kỹ thuật XAI được áp dụng. Phân tích vai trò của giải thích trong việc nâng cao độ tin cậy, hỗ trợ phát hiện mẫu gian lận mới. Từ đó đề xuất khung hướng dẫn lựa chọn và triển khai XAI cho các hệ thống phát hiện gian lận tài chính

6. Những đóng góp mới của đề tài

Đề tài mang lại những đóng góp quan trọng bằng việc tiên phong nghiên cứu hướng kết hợp giữa phát hiện gian lận và khả năng giải thích, một lĩnh vực mới có tiềm năng đóng góp thiết thực cho cả học thuật lẫn thực tiễn. Thông qua việc tích hợp các kỹ thuật trí tuệ nhân tạo giải thích được (XAI) vào các mô hình dự báo, nghiên cứu không chỉ góp phần thu hẹp khoảng cách tri thức hệ thống so với các công trình quốc tế mà còn xây dựng một khung thử nghiệm tích hợp XAI làm nền tảng cho các ứng dụng tương lai. Bên cạnh đó, đề tài còn đề xuất một khung hướng dẫn cụ thể về việc lựa chọn và triển khai XAI, từ đó tạo ra một hệ thống vừa đảm bảo hiệu năng thông minh vừa minh bạch, đáp ứng nhu cầu thực tế của ngành tài chính – ngân hàng và thúc đẩy việc ứng dụng AI có trách nhiệm tại Việt Nam.

7. Cấu trúc của đề tài

Mở đầu: Phần mở đầu trình bày bối cảnh và lý do lựa chọn đề tài trong bối cảnh chuyển đổi số và sự phát triển nhanh chóng của trí tuệ nhân tạo trong ngành tài chính. Nêu rõ tính cấp thiết của việc kết hợp giữa mô hình phát hiện gian lận và trí tuệ nhân tạo giải thích được (XAI) nhằm nâng cao tính minh bạch, tin cậy và khả năng ứng dụng thực tế. Phần này cũng xác định mục tiêu nghiên cứu, phạm vi thực hiện và phương pháp tiếp

cận tổng quát của đề tài.

- **Chương 1: Tổng quan đề tài**

- Phân tích tổng quan về gian lận tài chính, bao gồm các khái niệm, biểu hiện phổ biến và những thách thức trong việc nhận diện tự động.
- Giới thiệu các phương pháp phát hiện gian lận từ truyền thống đến hiện đại, nhấn mạnh vai trò của học máy (Machine Learning) và học sâu (Deep Learning).
- Tổng quan về XAI: định nghĩa, vai trò trong hệ thống ra quyết định, các kỹ thuật phổ biến và ứng dụng thực tiễn trong tài chính.
- Xác định rõ vấn đề nghiên cứu, mục tiêu, ý nghĩa khoa học, ý nghĩa thực tiễn và phạm vi giới hạn của đề tài.

- **Chương 2: Cơ sở lý thuyết và phương pháp nghiên cứu**

- Trình bày chi tiết các mô hình AI thường dùng trong phát hiện gian lận như Logistic Regression, Random Forest, Neural Networks, và LSTM.
- Phân tích các kỹ thuật XAI tiêu biểu (SHAP, LIME) cùng các tiêu chí đánh giá lời giải thích như độ trung thực, độ ổn định và tính dễ hiểu.
- Mô tả phương pháp tiếp cận kết hợp lý thuyết và thực nghiệm, quy trình chọn nguồn dữ liệu, huấn luyện, đánh giá và tích hợp XAI.

- **Chương 3: Thu thập, tiền xử lý dữ liệu và xây dựng mô hình phát hiện gian lận**

- Trình bày quá trình thu thập dữ liệu từ các nguồn công khai như Kaggle, UCI hoặc thông qua việc khởi tạo dữ liệu tổng hợp.
- Thực hiện các bước tiền xử lý: khám phá dữ liệu, xử lý giá trị thiếu, chuẩn hóa biến số, xử lý mất cân bằng lớp và mã hóa biến phân loại.
- Xây dựng, huấn luyện các mô hình nền tảng và đánh giá hiệu suất qua các chỉ số Accuracy, Precision, Recall, F1-score, và AUC.

- **Chương 4: Triển khai và tích hợp các kỹ thuật XAI**

- Lựa chọn các kỹ thuật XAI phù hợp nhất với đặc thù của mô hình và dữ liệu tài chính dạng bảng hoặc chuỗi thời gian.
- Tích hợp kỹ thuật vào mô hình để tạo ra các lời giải thích ở cả cấp độ cục bộ (local) và toàn cục (global).
- Giải quyết các vấn đề kỹ thuật về hiệu suất tính toán, tính tương thích đầu ra và tối ưu hóa cách hiển thị lời giải thích cho người dùng.

- **Chương 5: Thực nghiệm, đánh giá và phân tích kết quả**

- Thiết kế kịch bản thí nghiệm đánh giá chất lượng giải thích XAI dựa trên độ trung thực, tính dễ hiểu và độ ổn định.
- So sánh các kỹ thuật XAI trên cùng một bộ dữ liệu và mô hình để xác định ưu nhược điểm của từng phương pháp.
- Phân tích tác động của XAI đối với hiệu quả mô hình, khả năng hỗ trợ chuyên gia ra quyết định và tính ứng dụng thực tế.
- Thực hiện khảo sát người dùng để đánh giá tính hữu ích của lời giải thích từ góc nhìn chuyên gia hoặc kỹ thuật.

- **Chương 6: Kết luận và đề xuất**


- Tổng hợp kết quả đạt được và rút ra kết luận về hiệu quả của việc ứng dụng XAI trong phát hiện gian lận tài chính.
- Đề xuất hướng phát triển tương lai: mở rộng quy mô dữ liệu, nâng cấp thuật toán, cải thiện giao diện và tích hợp vào hệ thống thực tế.
- Hoàn thiện báo cáo tổng kết và đề xuất các đóng góp khoa học có giá trị để công bố trên các tạp chí chuyên ngành.

CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI

1.1 Nhu cầu thực tế

Trong kỷ nguyên số hóa hiện nay, sự phát triển mạnh mẽ của công nghệ tài chính (Fintech) đã thúc đẩy thói quen thanh toán không dùng tiền mặt trở nên phổ biến hơn bao giờ hết. Các phương thức giao dịch qua thẻ tín dụng và thanh toán trực tuyến mang lại sự thuận tiện lớn, nhưng đồng thời cũng tạo ra kẽ hở cho các hành vi gian lận tài chính ngày càng tinh vi và phức tạp. Gian lận thẻ tín dụng hiện đã trở thành một trong những loại tội phạm mạng gây lo ngại sâu sắc nhất trên phạm vi toàn cầu.

Theo số liệu từ báo cáo Nilson, thiệt hại do gian lận thẻ đã đạt tới mức 28,58 tỷ USD vào năm 2021 và con số này được dự báo sẽ tăng vọt lên đến 408,50 tỷ USD trong thập kỷ tới. Thực trạng này đặt các tổ chức tài chính trước áp lực phải xây dựng được những hệ thống phát hiện giao dịch đáng ngờ một cách kịp thời và hiệu quả để giảm thiểu tổn thất.



Hình 1.1 Thống kê và dự báo thiệt hại do gian lận thẻ toàn cầu theo báo cáo Nilson

Tuy nhiên, thách thức lớn nhất hiện nay không chỉ nằm ở khả năng phát hiện mà

còn ở sự minh bạch của hệ thống. Các mô hình học máy hiện đại dù đạt hiệu năng cao nhưng thường hoạt động như một "hộp đen", khiến người dùng và các cơ quan quản lý khó có thể lý giải được cơ sở đằng sau các quyết định phân loại. Trong bối cảnh tài chính, nơi các quy định pháp lý và yêu cầu kiểm toán ngày càng nghiêm ngặt, việc thiếu tính giải thích sẽ gây cản trở lớn cho việc ứng dụng AI vào thực tế.

Chính vì vậy, nhu cầu thực tế đòi hỏi một hệ thống phát hiện gian lận không chỉ đảm bảo độ chính xác cao mà còn phải có khả năng giải thích (XAI). Điều này không chỉ giúp các chuyên gia hiểu rõ các yếu tố rủi ro để đưa ra quyết định chính xác hơn mà còn giúp xây dựng lòng tin bền vững với khách hàng trong môi trường tài chính số.

1.2 Các phương pháp phát hiện gian lận tài chính

Lịch sử của các phương pháp phát hiện gian lận đã chuyển dịch từ việc điều tra thủ công dựa trên kinh nghiệm sang việc ứng dụng các thuật toán tự động hóa. Ban đầu, các mô hình học máy truyền thống như Hồi quy Logistic hay Naive Bayes đóng vai trò nền tảng trong việc phân loại các hành vi bất thường dựa trên hồ sơ giao dịch quá khứ.

Sự ra đời của các phương pháp học máy kết hợp như Random Forest hay XGBoost đã mang lại bước tiến lớn về hiệu năng dự báo. Tuy nhiên, các kiến trúc học sâu hiện đại, tiêu biểu là TabNet, mới thực sự tạo ra đột phá khi có khả năng tự động học các đặc trưng phức tạp từ dữ liệu dạng bảng mà không cần quá nhiều sự can thiệp thủ công từ con người.

Mặc dù đạt được độ chính xác cao, phần lớn các mô hình học sâu này vẫn gặp hạn chế về tính minh bạch. Việc hoạt động như một "hộp đen" khiến quá trình ra quyết định của máy tính trở nên khó hiểu đối với các chuyên gia tài chính, từ đó cản trở việc triển khai rộng rãi trong các môi trường yêu cầu tính kiểm toán cao.

1.3 Tổng quan về Trí tuệ nhân tạo giải thích được (XAI)

Trí tuệ nhân tạo giải thích được (XAI) nổi lên như một giải pháp then chốt để giải quyết bài toán "hộp đen" của AI. Mục tiêu cốt lõi của XAI là tạo ra các mô hình không chỉ thông minh mà còn phải minh bạch, cho phép con người hiểu rõ lý do tại sao một quyết định cụ thể lại được đưa ra bởi hệ thống.

Trong lĩnh vực tài chính, XAI cung cấp các công cụ như SHAP hay LIME để phân

tích mức độ ảnh hưởng của từng đặc trưng lên kết quả dự báo. Điều này không chỉ giúp gia tăng độ tin cậy của hệ thống mà còn hỗ trợ các chuyên gia trong việc truy vết và xác định các mẫu gian lận mới một cách chính xác hơn.

Bên cạnh đó, các phương pháp như giải thích phản thực tế (DiCE) giúp người dùng hình dung các kịch bản thay đổi dữ liệu để thay đổi kết quả dự báo. Khả năng này cực kỳ quan trọng trong việc xây dựng một hệ thống AI có trách nhiệm, đảm bảo tính công bằng và tuân thủ các quy định khắt khe của ngành ngân hàng.

1.4 Vấn đề nghiên cứu và mục tiêu của đề tài

Tại Việt Nam, việc ứng dụng AI trong phát hiện gian lận chủ yếu vẫn tập trung vào việc tối ưu hóa độ chính xác mà chưa thực sự chú trọng đến khả năng giải thích của mô hình. Điều này tạo ra một khoảng trống nghiên cứu đáng kể, đặc biệt là khi yêu cầu về tính minh bạch trong các giao dịch tài chính ngày càng trở nên cấp thiết.

Đề tài này được thực hiện nhằm xây dựng một mô hình phát hiện gian lận minh bạch dựa trên sự kết hợp giữa kiến trúc TabNet và các kỹ thuật XAI tiên tiến. Mục tiêu chính là tạo ra một hệ thống vừa đảm bảo hiệu suất dự báo vượt trội trên các tập dữ liệu lớn, vừa cung cấp các lời giải thích rõ ràng để hỗ trợ người dùng cuối.

Hệ thống hướng tới việc cung cấp khả năng giải thích ở cả cấp độ cục bộ cho từng giao dịch và cấp độ toàn cục cho toàn bộ mô hình. Qua đó, đề tài hy vọng sẽ mang lại một giải pháp thiết thực, đáp ứng được cả yêu cầu về kỹ thuật lẫn các tiêu chuẩn về niềm tin và pháp lý trong kỷ nguyên số.

1.5 Ý nghĩa khoa học và thực tiễn

Về mặt khoa học, nghiên cứu đóng góp vào việc hệ thống hóa các kỹ thuật giải thích mô hình dành riêng cho dữ liệu dạng bảng trong lĩnh vực tài chính. Việc tích hợp XAI vào các mô hình học sâu không chỉ mở ra hướng đi mới cho nghiên cứu AI mà còn góp phần thu hẹp khoảng cách công nghệ giữa Việt Nam và thế giới.

Về mặt thực tiễn, đề tài cung cấp một công cụ hỗ trợ đắc lực cho các tổ chức tài chính trong việc kiểm soát rủi ro và ngăn chặn tổn thất. Khả năng giải thích của mô hình giúp giảm thiểu các cảnh báo sai, từ đó nâng cao trải nghiệm của khách hàng và tối ưu hóa chi phí vận hành cho các ngân hàng.

Ngoài ra, kết quả của nghiên cứu còn có khả năng mở rộng sang các lĩnh vực nhạy cảm khác như bảo hiểm hay cho vay trực tuyến. Đây là nền tảng quan trọng để thúc đẩy việc ứng dụng trí tuệ nhân tạo một cách bền vững và có trách nhiệm tại Việt Nam.

1.6 Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu trọng tâm là các phương pháp luận của trí tuệ nhân tạo giải thích được và cách thức vận hành của mô hình TabNet trên dữ liệu giao dịch tài chính. Đề tài tập trung phân tích các thuật toán như SHAP, LIME và DiCE để xây dựng khung đánh giá tính minh bạch cho các quyết định dự báo gian lận.

Phạm vi nghiên cứu được giới hạn trong việc phát hiện gian lận thẻ tín dụng và thanh toán trực tuyến thông qua thực nghiệm trên các bộ dữ liệu công khai như MLG-ULB, IEEE-CIS và Sparkov. Toàn bộ quá trình triển khai sẽ sử dụng các thư viện mã nguồn mở và ngôn ngữ lập trình Python để đảm bảo tính kế thừa và phát triển.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ PHƯƠNG PHÁP NGHIÊN CỨU

2.1 Bài toán Phát hiện Gian lận: Từ Góc nhìn Thống kê đến Học máy

Trong kỷ nguyên tài chính số, phát hiện gian lận thẻ tín dụng không đơn thuần là một bài toán phân loại nhị phân (Binary Classification) lý thuyết, mà thực chất là một cuộc chạy đua vũ trang giữa các hệ thống bảo mật và những hành vi phạm tội ngày càng tinh vi. Những kẻ gian lận liên tục thay đổi chiến thuật để ngụy trang các giao dịch bất hợp pháp sao cho giống với hành vi tiêu dùng bình thường nhất có thể.

2.1.1 Sự giới hạn của các Mô hình Tuyến tính

Các mô hình nền tảng như Hồi quy Logistic (Logistic Regression) thường được thiết lập làm điểm chuẩn (baseline). Về mặt toán học, mô hình này giả định rằng logarit của tỷ lệ cược (log-odds) có mối quan hệ tuyến tính với các đặc trưng đầu vào $X = [x_1, x_2, \dots, x_n]^T$:

$$\ln \left(\frac{P(Y = 1|X)}{1 - P(Y = 1|X)} \right) = W^T X + b \quad (2.1)$$

Thông qua hàm Sigmoid, ranh giới tuyến tính này được ánh xạ thành xác suất hậu nghiệm:

$$\hat{y} = \frac{1}{1 + e^{-(W^T X + b)}} \quad (2.2)$$


Mặc dù thanh lịch về mặt toán học, Hồi quy Logistic bộc lộ điểm yếu chí mạng: nó kỳ vọng một sự phân tách tuyến tính rõ ràng. Trong thực tế, giao dịch thường là kết quả của một chuỗi các điều kiện phi tuyến: "Số tiền lớn" **nhưng** "phát sinh lúc 3 giờ sáng" **và** "từ một địa chỉ IP chưa từng xuất hiện". Mô hình tuyến tính thất bại trong việc mô hình hóa các tương tác chéo (feature interactions) phức tạp này.

2.2 Lý thuyết Học Kết hợp (Ensemble Learning) và Boosting

Để vượt qua giới hạn của ranh giới tuyến tính, phân tích dữ liệu tài chính ưu tiên các mô hình dựa trên cây quyết định (Decision Trees) và Học kết hợp (Ensemble Learning) như Random Forest hay XGBoost.

Nếu Random Forest (dựa trên Bagging) đóng vai trò như các chuyên gia làm việc độc lập, thì Gradient Boosting lại giống như một đội ngũ sửa lỗi dây chuyền. Các thuật

toán như XGBoost xây dựng cây tuần tự, trong đó cây sau tập trung học từ những sai lầm (residuals) của cây trước đó.



Hình 2.1 Quy trình tối ưu hóa lỗi tuần tự trong Gradient Boosting


XGBoost định nghĩa hàm mục tiêu tại bước thứ t không chỉ quan tâm đến việc giảm sai số $\mathcal{L}$, mà còn chủ động kiểm soát độ phức tạp thông qua thành phần điều chuẩn Ω :

$$\mathcal{O}^{(t)} = \sum_{i=1}^n \mathcal{L}(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \quad (2.3)$$

Sử dụng khai triển Taylor bậc hai, thuật toán xấp xỉ hàm mục tiêu bằng đạo hàm bậc nhất (g_i) và bậc hai (h_i), cho phép tìm ra cấu trúc ranh giới tối ưu nhanh chóng.

2.3 Bước tiến của Học Sâu: Kiến trúc và Toán học trong TabNet

Mạng nơ-ron truyền thẳng (FFNN) truyền thống thường bị "choáng ngợp" bởi cấu trúc dữ liệu bảng do các kết nối dày đặc (dense connections) gây ra hiện tượng học nhiễu. **TabNet** giải quyết triệt để vấn đề này bằng cách đưa khái niệm *Chú ý Tuần tự* (*Sequential Attention*) vào không gian dữ liệu bảng. Quá trình ra quyết định của TabNet không diễn ra trong một lần, mà được chia thành N_{steps} bước liên tiếp.



Hình 2.2 Kiến trúc tổng thể của mô hình TabNet (TabNet Model Architecture)

Mỗi bước quyết định i trong TabNet được cấu thành từ hai khối toán học cốt lõi:

1. Khối Chú ý (Attentive Transformer): Đóng vai trò như bộ chọn lọc đặc trưng. Thay vì dùng Softmax, TabNet tính toán một mặt nạ thông qua hàm **Sparsemax** để ép các biến nhiễu về đúng bằng 0:

$$M[i] = \text{sparsemax}(P[i-1] \cdot h_i(a[i-1])) \quad (2.4)$$

Trong đó, $P[i-1]$ là *Điều kiện tiên nghiệm (Prior Scale)*. Nó đóng vai trò "trí nhớ" của mạng, giảm dần trọng số của các đặc trưng đã được sử dụng nhiều ở các bước trước (được truyền qua luồng mũi tên đỏ):

$$P[i] = \prod_{j=1}^{i-1} (\gamma - M[j]) \quad (2.5)$$

với tham số nói lỏng $\gamma \geq 1$. Cơ chế này buộc mô hình phải khai thác các đặc trưng mới, tránh phụ thuộc thái quá vào một biến duy nhất.

2. Khối Biến đổi Đặc trưng (Feature Transformer): Xử lý vector dữ liệu đã được áp mặt nạ ($X \odot M[i]$). Khối này sử dụng các lớp kết nối đầy đủ (Fully Connected), Chuẩn hóa theo lô (Batch Normalization) và hàm kích hoạt GLU (Gated Linear Unit). Đầu ra của Feature Transformer được tách qua khối **SPLIT** làm hai phần:


- Một phần đi lên qua hàm **ReLU** để đóng góp vào dự đoán cuối cùng (Output).
- Một phần đi theo luồng màu đỏ để hướng dẫn *Attentive Transformer* của bước tiếp theo tạo mặt nạ mới.

Ngoài ra, các mặt nạ $M[i]$ còn được tổng hợp lại qua khối **AGG** để trích xuất **FEATURE ATTRIBUTES**, cung cấp khả năng minh bạch hóa nội tại (built-in interpretability) phục vụ cho việc giải thích mô hình.

2.4 Hình học không gian mẫu: Vượt qua rào cản Mất cân bằng (SMOTE)

Dữ liệu gian lận tài chính luôn ở trạng thái mất cân bằng nghiêm trọng (Class Imbalance). Để bẻ gãy sự thiên lệch này, SMOTE (Synthetic Minority Oversampling Technique) định hình lại phân phối không gian bằng cách nội suy tuyến tính.

Cho một giao dịch gian lận x_i , một mẫu tổng hợp mới x_{new} được sinh ra bằng cách



Hình 2.3 Biểu diễn hình học của kỹ thuật nội suy SMOTE trong không gian đặc trưng

lấy một điểm ngẫu nhiên dọc theo đoạn thẳng nối x_i và láng giềng $x_{i,j}$:

$$x_{new} = x_i + \lambda \times (x_{i,j} - x_i) \quad \text{với } \lambda \sim \mathcal{U}(0, 1) \quad (2.6)$$

Hệ quả toán học của phép nội suy này là nó làm giãn nở biên giới hình học của lớp thiểu số, buộc ranh giới quyết định của mô hình phải điều chỉnh để bao trọn không gian của hành vi gian lận.

2.5 Trí tuệ Nhân tạo Giải thích được (XAI): Chìa khóa của sự Tin cậy

Trong tài chính, từ chối giao dịch phải đi kèm với lý do minh bạch. Giá trị SHAP tính toán đóng góp biên (marginal contribution) của mỗi đặc trưng trên mọi tổ hợp có thể xảy ra để đảm bảo phân bổ công bằng:


$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [v(S \cup \{i\}) - v(S)] \quad (2.7)$$

Trong khi SHAP cung cấp cái nhìn tổng cục, LIME lại tối ưu hóa xấp xỉ tuyến tính tại một vùng cục bộ bằng cách giải bài toán:

$$\xi(x) = \arg \min_{g \in G} \mathcal{L}(f, g, \pi_x) + \Omega(g) \quad (2.8)$$

2.6 Phương pháp Nghiên cứu (Research Methodology)

Nghiên cứu này được thiết kế dựa trên phương pháp kết hợp giữa nghiên cứu định lượng (Quantitative Research) và thực nghiệm mô phỏng (Empirical Simulation). Quy trình nghiên cứu được triển khai một cách hệ thống qua 4 giai đoạn cốt lõi:



Hình 2.4 Sơ đồ quy trình nghiên cứu hệ thống 4 giai đoạn

1. Thu thập và Xử lý Dữ liệu (Data Engineering): Tiếp cận theo phương pháp hồi cứu trên các tập dữ liệu thứ cấp (secondary data) mang tính đại diện cao. Ba bộ dữ liệu công khai (MLG-ULB, IEEE-CIS, Sparkov) được thu thập để đảm bảo tính đa dạng của không gian đặc trưng (từ dữ liệu bị ẩn danh hóa bằng PCA đến dữ liệu giữ nguyên thông tin nhân khẩu học thực tế). Quá trình tiền xử lý áp dụng các phương pháp toán học nghiêm ngặt: chuẩn hóa Z-score để đưa các thang đo phân kỳ về phân phối chuẩn, điền khuyết bằng hằng số cố định, và giải quyết rào cản mất cân bằng lớp (Class Imbalance) bằng thuật toán SMOTE trên tập huấn luyện để tránh rò rỉ dữ liệu (data leakage).

2. Phương pháp Mô hình hóa (Modeling Approach): Triển khai thực nghiệm có đối chứng (Controlled Experiment). Mô hình đề xuất TabNet được xây dựng và tinh chỉnh siêu tham số thông qua thuật toán giảm Gradient (Gradient Descent) với hàm mất mát Cross-Entropy tích hợp thành phần phạt thưa thớt (Sparse Regularization). Hiệu suất của TabNet được so sánh trực tiếp với 12 thuật toán thuộc nhóm mô hình tuyến tính (Logistic Regression) và học kết hợp (Random Forest, XGBoost, LightGBM) dưới cùng

một điều kiện phân chia tập huấn luyện/kiểm thử.

3. Phương pháp Đánh giá Hiệu suất (Performance Evaluation): Vì tính chất mất cân bằng tự nhiên của bài toán phát hiện gian lận, phương pháp đánh giá từ chối sử dụng Độ chính xác tổng quát (Accuracy). Thay vào đó, nghiên cứu dựa vào Ma trận Nhầm lẫn (Confusion Matrix) để tính toán các độ đo định lượng chuyên sâu:

- **Độ chính xác dự báo (Precision):** Hạn chế rủi ro hệ thống đóng băng nhầm thẻ của khách hàng hợp lệ (False Positives).
- **Độ nhạy (Recall):** Đảm bảo khả năng quét và bắt chặn tối đa tội phạm gian lận thực tế (False Negatives).
- **F1-Score:** Được sử dụng làm thước đo xếp hạng tối thượng, đại diện cho trung bình điều hòa giữa Precision và Recall.

4. Phương pháp Phân tích Giải thích (XAI Integration): Sử dụng phương pháp diễn dịch ngược (Reverse Engineering) đối với mô hình hộp đen thông qua các công cụ SHAP, LIME và DiCE. Lời giải thích của XAI được phân tích dựa trên phương pháp luận đánh giá chéo (Cross-validation of Explanations): kiểm tra tính đồng thuận giữa sự đóng góp toàn cục (Global feature importance từ SHAP) và phân tích ngưỡng cục bộ (Local bounds từ LIME), đồng thời sử dụng các kịch bản phản thực tế (Counterfactual scenarios) của DiCE để đưa ra các đề xuất mang tính hành động hỗ trợ chuyên gia quản trị rủi ro.

CHƯƠNG 3: QUY TRÌNH THỰC NGHIỆM VÀ XÂY DỰNG MÔ HÌNH

3.1 Thu thập và Phân tích Tập dữ liệu Thực nghiệm (EDA)

Để đảm bảo tính khách quan, sự tin cậy và khả năng đánh giá mức độ tổng quát hóa của hệ thống phát hiện gian lận trong nhiều kịch bản tài chính khác nhau, nghiên cứu này tiến hành thực nghiệm song song trên ba tập dữ liệu giao dịch thẻ tín dụng quy mô lớn. Các tập dữ liệu này bao phủ từ dữ liệu ẩn danh của Châu Âu, dữ liệu thương mại điện tử toàn cầu, đến dữ liệu mô phỏng tổng hợp.

3.1.1 Tập dữ liệu MLG-ULB (Châu Âu)

Tập dữ liệu này được thu thập bởi Machine Learning Group - Đại học Université Libre de Bruxelles (ULB), bao gồm 284,807 giao dịch thẻ tín dụng của người dùng Châu Âu trong hai ngày vào tháng 9 năm 2013. Đặc điểm nổi bật của tập dữ liệu này là sự **mất cân bằng cực đoan (extreme class imbalance)**: chỉ có 492 giao dịch được dán nhãn gian lận, chiếm tỷ lệ 0.172%.

Về không gian đặc trưng, ngoại trừ hai biến Time (số giây trôi qua giữa giao dịch hiện tại và giao dịch đầu tiên) và Amount (số tiền giao dịch), 28 biến còn lại ($V_1, V_2, \dots, V_{28}$) đều đã được ẩn danh hóa bằng phép biến đổi **Phân tích Thành phần Chính (PCA - Principal Component Analysis)** nhằm tuân thủ quy định bảo mật thông tin tài chính cá nhân. Phép chiếu PCA lên ma trận hiệp phương sai của dữ liệu gốc được định nghĩa là:

$$Y = XW \quad (3.9)$$

với X là ma trận dữ liệu gốc đã chuẩn hóa, và W là ma trận chứa các vector riêng (eigenvector) tương ứng với các giá trị riêng (eigenvalue) lớn nhất, đảm bảo giữ lại phương sai lớn nhất của dữ liệu.

3.1.2 Tập dữ liệu IEEE-CIS Fraud Detection

Được cung cấp bởi Vesta Corporation (công ty thanh toán thương mại điện tử hàng đầu), tập dữ liệu này phức tạp hơn rất nhiều, chứa cả thông tin định danh (Identity) và thông tin giao dịch (Transaction) được liên kết thông qua khóa TransactionID. Tập dữ

liệu có tổng cộng 590,540 dòng và 394 cột đặc trưng, bao gồm:

- **Đặc trưng phân loại (Categorical):** Loại thẻ (ProductCD, card1 - card6), Miền email (P_emaildomain), Thông tin thiết bị (DeviceType, DeviceInfo).
- **Đặc trưng số liên tục (Numerical):** Số tiền (TransactionAmt), Khoảng cách (dist1, dist2), và các đặc trưng Vesta engineered (V_1 đến V_{339}).

Tỷ lệ gian lận trong tập này là xấp xỉ 3.5% (20,663 mẫu gian lận). Thách thức lớn nhất của bộ dữ liệu này là mức độ nhiễu và tỷ lệ dữ liệu khuyết (missing values) rất cao ở nhiều cột.

3.1.3 Tập dữ liệu Sparkov (Dữ liệu tổng hợp)

Để kiểm chứng năng lực của mô hình trên cấu trúc dữ liệu không bị ẩn danh hóa, nghiên cứu sử dụng tập dữ liệu Sparkov. Đây là một tập dữ liệu tổng hợp (synthetic) mô phỏng hành vi giao dịch của 1,000 khách hàng tại 800 cửa hàng từ 01/2019 đến 12/2020. Nó chứa 1,289,169 giao dịch hợp lệ và 7,506 giao dịch gian lận (0.58%). Khác với MLG-ULB, các đặc trưng của Sparkov hoàn toàn có thể diễn dịch trực tiếp như category (nhóm ngành hàng), amt (số tiền), gender (giới tính), city_pop (dân số thành phố), cung cấp cơ sở vững chắc cho các công cụ giải thích mô hình (XAI) sau này.

3.2 Kỹ thuật Tiền xử lý và Làm sạch Dữ liệu (Data Preprocessing)

Dữ liệu thô trong lĩnh vực tài chính không bao giờ ở trạng thái lý tưởng. Quá trình tiền xử lý là xương sống quyết định hiệu năng của bất kỳ mô hình học máy nào.

3.2.1 Xử lý Dữ liệu Khuyết (Missing Value Imputation)

Đối với tập IEEE-CIS, bước đầu tiên là sàng lọc các đặc trưng rác. Bất kỳ cột nào có tỷ lệ khuyết lớn hơn 50% số lượng mẫu đều bị loại bỏ hoàn toàn, vì việc cố gắng nội suy chúng sẽ đưa thêm nhiễu vào mô hình. Đối với các biến phân loại và biến số còn lại, nghiên cứu không sử dụng phương pháp điền giá trị trung bình/trung vị (Mean/Median Imputation) vì nó làm giảm phương sai tự nhiên của dữ liệu. Thay vào đó, **điền hằng số cố định (Constant Imputation)** (ví dụ: -999 cho biến số và "Unknown" cho biến phân loại) được áp dụng. Cách tiếp cận này giúp mô hình TabNet tự học được việc "thiếu dữ liệu" cũng chính là một tín hiệu (signal) quan trọng để nhận diện gian lận.

3.2.2 Chuẩn hóa (Feature Scaling) và Mã hóa (Encoding)

Các thuật toán tối ưu hóa bằng Gradient Descent rất nhạy cảm với thang đo của dữ liệu. Nếu Amount có giá trị lên tới hàng nghìn trong khi Time có giá trị nhỏ, mô hình sẽ thiên lệch trọng số về phía Amount. Để khắc phục, toàn bộ biến số liên tục được chuẩn hóa Z-score (Standardization):

$$X_{\text{scaled}} = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1) \quad (3.10)$$

Quá trình này chuyển hóa phân phối của từng đặc trưng về dạng có giá trị trung bình $\mu = 0$ và độ lệch chuẩn $\sigma = 1$.

Đối với các biến phân loại dạng văn bản (ví dụ: `card_type`), kỹ thuật **Mã hóa One-Hot (One-Hot Encoding)** được áp dụng để chuyển chúng thành các vector nhị phân thưa thớt (sparse binary vectors). Điều này tránh việc mô hình hiểu nhầm các nhãn phân loại thành một thứ tự có độ lớn toán học.

3.2.3 Xử lý Mất cân bằng Lớp bằng thuật toán SMOTE

Mất cân bằng dữ liệu là nguyên nhân chính dẫn đến hiện tượng mô hình dự đoán theo lớp đa số. Kỹ thuật **SMOTE (Synthetic Minority Oversampling Technique)** được áp dụng nghiêm ngặt **chỉ trên tập huấn luyện (Training Set)** để ngăn chặn hiện tượng rò rỉ dữ liệu (Data Leakage).

Thuật toán SMOTE hoạt động qua các bước sau:

1. Xét từng điểm dữ liệu x_i thuộc lớp thiểu số (gian lận).
2. Tính toán khoảng cách Euclid tới tất cả các điểm thiểu số khác và chọn ra k láng giềng gần nhất (trong nghiên cứu này $k = 5$).
3. Chọn ngẫu nhiên một láng giềng $x_{i,j}$ và sinh ra mẫu tổng hợp x_{new} thông qua phương trình nội suy hình học:

$$x_{\text{new}} = x_i + \lambda \cdot (x_{i,j} - x_i) \quad \text{với } \lambda \sim \mathcal{U}(0, 1) \quad (3.11)$$

Sau quá trình này, phân phối giữa lớp hợp lệ và gian lận trong tập huấn luyện đạt tỷ lệ 1 : 1, tạo điều kiện lý tưởng cho các mô hình học sâu tối ưu hóa ranh giới quyết định.

3.3 Thiết lập Kiến trúc Mô hình và Môi trường Thực nghiệm

3.3.1 Thiết lập các Mô hình Nền tảng (Baseline Models)

Để đánh giá tính ưu việt của mô hình đề xuất, một loạt các thuật toán học máy từ cổ điển đến hiện đại được thiết lập để so sánh đối chuẩn:

- **Logistic Regression & Naive Bayes:** Thiết lập làm các đường cơ sở tuyến tính.
- **Random Forest (RF):** Số lượng cây $n_estimators = 100$, max_depth không giới hạn.
- **Gradient Boosting (XGBoost, LightGBM, CatBoost):** Sử dụng hàm mục tiêu `binary:logistic`. Tốc độ học $\eta = 0.1$, số cây đánh giá là 200. Thuật toán được tinh chỉnh trọng số lớp `scale_pos_weight` hỗ trợ học trên dữ liệu mất cân bằng.

3.3.2 Thiết lập Kiến trúc Học sâu TabNet

TabNet là kiến trúc nòng cốt của đề tài. Quá trình thiết lập mô hình đòi hỏi việc định nghĩa rõ ràng các siêu tham số (Hyperparameters):

- **Chiều đặc trưng:** Số chiều quyết định $N_d = 64$ và chiều chú ý $N_a = 64$.
- **Hàm mất mát (Loss Function):** Sử dụng Cross-Entropy Loss kết hợp với thành phần điều chuẩn độ thưa thớt (Sparse Regularization) nhằm ép mô hình chỉ tập trung vào một số ít đặc trưng. Tổng hàm mất mát tại bước i là:

$$\mathcal{L} = \mathcal{L}_{CE}(y, \hat{y}) + \lambda_{sparse} \sum_{i=1}^{steps} \sum_{b=1}^B \frac{-1}{N_d} M_{b,i} \log(M_{b,i} + \epsilon) \quad (3.12)$$

- **Tối ưu hóa:** Adam Optimizer ($lr = 0.02$), kết hợp cơ chế giảm tốc độ học StepLR.
- **Kích thước Lô & Epochs:** Batch size = 1024, huấn luyện tối đa 100 epochs với cơ chế Early Stopping nhằm chống overfitting.

3.4 Chiến lược Đánh giá và Các Chỉ số Hiệu suất

Nghiên cứu áp dụng quy trình kiểm định chéo phân tầng **Stratified K-Fold Cross Validation** ($K = 5$) để đảm bảo tỷ lệ gian lận trong các tập huấn luyện/kiểm thử luôn đồng nhất.

Dựa trên Ma trận Nhầm lẫn (Confusion Matrix), các chỉ số được định nghĩa như sau:

1. Độ chính xác dự báo (Precision): Đo lường xác suất một giao dịch bị hệ thống cảnh báo thực sự là tội phạm gian lận. Tối ưu hóa Precision giúp ngân hàng giảm thiểu việc làm phiền khách hàng chân chính (False Positives).

$$\text{Precision} = \frac{TP}{TP + FP} \quad (3.13)$$

2. Độ nhạy / Độ phủ (Recall): Trong tổng số tội phạm gian lận đang hoạt động, hệ thống bắt được bao nhiêu phần trăm? Tối ưu hóa Recall giảm thiểu tổn thất tài chính trực tiếp (False Negatives).

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3.14)$$

3. Điểm F1-Score: Là trung bình điều hòa, ép mô hình phải cân bằng cả hai yếu tố trên. Đây là tiêu chí xếp hạng mô hình quan trọng nhất.

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3.15)$$

4. Diện tích dưới đường cong (ROC-AUC & PR-AUC): ROC-AUC đo lường khả năng phân biệt chung qua nhiều ngưỡng phân loại. Tuy nhiên, đối với dữ liệu mất cân bằng nghiêm trọng, nghiên cứu sử dụng thêm **PR-AUC (Precision-Recall Area Under Curve)**. Đường cong PR tập trung trực tiếp vào lớp thiểu số (gian lận), phơi bày điểm yếu của các thuật toán dự đoán nhầm, mang lại cái nhìn chính xác hơn về hiệu suất thực sự của hệ thống.

CHƯƠNG 4: TRIỂN KHAI VÀ TÍCH HỢP CÁC KỸ THUẬT TRÍ TUỆ NHÂN TẠO GIẢI THÍCH ĐƯỢC (XAI)

4.1 Lựa chọn Kỹ thuật XAI cho Dữ liệu Tài chính dạng Bảng

Dữ liệu tài chính trong bài toán phát hiện gian lận thẻ tín dụng mang những đặc thù rất riêng: nó là dữ liệu dạng bảng (tabular data), chứa cả biến số liên tục lẫn biến phân loại, có tính phi tuyến tính cao và đôi khi mang yếu tố chuỗi thời gian (lịch sử giao dịch). Do đó, việc áp dụng các kỹ thuật XAI dành cho xử lý ảnh (như Grad-CAM) hay văn bản (như Attention Weights của Transformer) là không khả thi.

Dựa trên cấu trúc của mạng TabNet và bản chất của bộ dữ liệu thực nghiệm (MLG-ULB, IEEE-CIS, Sparkov), nghiên cứu lựa chọn ba phương pháp giải thích bổ trợ lẫn nhau, tạo thành một hệ sinh thái minh bạch toàn diện:

- **Giải thích Nội tại (Built-in Interpretability) của TabNet:** Tận dụng trực tiếp các mặt nạ thưa thớt (Sparse Masks) được sinh ra từ Attentive Transformer tại mỗi bước quyết định. Phương pháp này không tốn thêm chi phí tính toán và phản ánh chính xác 100% cách mô hình định tuyến thông tin.
- **SHAP (SHapley Additive exPlanations):** Được lựa chọn làm phương pháp chủ đạo nhờ nền tảng toán học vững chắc từ Lý thuyết trò chơi. SHAP là phương pháp duy nhất hiện nay đảm bảo được tính nhất quán (Consistency) và tính cộng gộp (Additivity), cực kỳ phù hợp để đánh giá tầm quan trọng của các biến tài chính (như Amount, Time, V14) trên bình diện cả cục bộ lẫn toàn cục.
- **LIME (Local Interpretable Model-Agnostic Explanations) và DiCE:** Mặc dù SHAP rất mạnh mẽ, nhưng việc giải thích cho một nhân viên kiểm soát rủi ro đôi khi cần những ranh giới logic "NẾU-THÌ" rõ ràng hoặc các kịch bản "Phản thực tế" (Counterfactual). LIME xấp xỉ ranh giới tuyến tính, trong khi DiCE chỉ ra đích xác điều kiện cần thay đổi để một giao dịch bị chặn chuyển thành hợp lệ.

4.2 Tích hợp XAI: Xây dựng Cầu nối từ Cục bộ đến Toàn cục

Quá trình tích hợp không chỉ đơn thuần là gọi các thư viện có sẵn, mà là việc ánh xạ các đầu ra toán học của mô hình học sâu vào các khung giải thích (explanation

frameworks).

4.2.1 Cấp độ Cục bộ (Local Explanations): Phân tích Từng Giao dịch

Giải thích cục bộ trả lời câu hỏi: *"Tại sao giao dịch mang mã số #1042 của khách hàng này lại bị hệ thống gắn cờ gian lận với xác suất 98%?"*

Để làm điều này, hệ thống trích xuất giá trị SHAP cục bộ (ϕ_i) cho từng đặc trưng của điểm dữ liệu x . Giá trị dự đoán cuối cùng $f(x)$ được phân rã thành tổng của giá trị nền (base value - giá trị kỳ vọng của toàn bộ tập dữ liệu) và các đóng góp biên:

$$f(x) = \phi_0 + \sum_{i=1}^M \phi_i(x) \quad (4.16)$$

Ví dụ, hệ thống XAI sẽ xuất ra diễn giải: Xác suất gian lận bị đẩy lên cao chủ yếu do đặc trưng V_{14} có giá trị bất thường (đóng góp +0.35), kết hợp với khoảng cách địa lý (dist1) lớn (đóng góp +0.20), bất chấp việc số tiền giao dịch (Amount) nằm trong ngưỡng an toàn (đóng góp -0.05).

4.2.2 Cấp độ Toàn cục (Global Explanations): Thấu hiểu Hành vi Hệ thống

Giải thích toàn cục trả lời câu hỏi: *"Nhìn chung, hệ thống AI đang dựa vào những yếu tố cốt lõi nào để phân biệt kẻ gian lận và người dùng chân chính?"*


Nghiên cứu tính toán độ quan trọng đặc trưng toàn cục I_j bằng cách lấy trung bình trị tuyệt đối của các giá trị SHAP đối với đặc trưng j trên toàn bộ tập dữ liệu kiểm thử có kích thước N :

$$I_j = \frac{1}{N} \sum_{i=1}^N |\phi_j^{(i)}| \quad (4.17)$$

Cách tiếp cận này vạch trần các chiến lược học máy của TabNet. Thay vì chỉ đếm số lần phân nhánh như Random Forest, SHAP tính toán mức độ tác động thực tế của từng biến lên biên độ xác suất. Biểu đồ *SHAP Summary Plot* được tích hợp để hiển thị không chỉ độ quan trọng mà còn cả chiều tác động (ví dụ: biến Time giá trị cao thì làm giảm xác suất gian lận, biến V_4 giá trị cao thì làm tăng xác suất).

4.3 Giải quyết Thách thức Kỹ thuật và Tối ưu hóa Trực quan hóa

Việc chuyển đổi XAI từ lý thuyết sang một hệ thống vận hành thực tế (production) đối mặt với những rào cản kỹ thuật khổng lồ, đặc biệt là tài nguyên tính toán và trải nghiệm người dùng.



Hình 4.1 Kiến trúc Tích hợp Kỹ thuật XAI đa cấp độ vào Hệ thống Phát hiện Gian lận

4.3.1 Bài toán Hiệu suất: Nút thắt Tính toán của SHAP

Định lý Shapley yêu cầu phải tính toán mọi tổ hợp có thể có của các đặc trưng. Với tập dữ liệu IEEE-CIS có tới gần 400 đặc trưng, độ phức tạp thời gian là $\mathcal{O}(2^M)$, một con số bất khả thi về mặt tính toán ngay cả với các siêu máy tính.

Để giải quyết vấn đề này, nghiên cứu áp dụng hai kỹ thuật tối ưu hóa:

1. **Sử dụng DeepSHAP thay vì KernelSHAP:** Đối với kiến trúc học sâu như TabNet, bộ giải thích DeepExplainer (DeepSHAP) được tích hợp. Thuật toán này tận dụng thuật toán truyền ngược (backpropagation) của mạng nơ-ron và phương pháp DeepLIFT để tính xấp xỉ giá trị SHAP, giảm thời gian tính toán từ vài giờ xuống còn vài phút.
2. **Lấy mẫu nền tĩnh (Background Sampling bằng K-Means):** SHAP cần một tập dữ liệu nền (background dataset) để so sánh các giá trị kỳ vọng. Việc dùng toàn bộ 284,807 giao dịch làm nền sẽ làm tràn bộ nhớ (Out-Of-Memory). Nghiên cứu giải quyết bằng cách áp dụng thuật toán phân cụm K-Means để nén tập dữ liệu nền xuống còn 100 điểm đại diện (centroids) mang đầy đủ phân phối thống kê, tối ưu hóa tới 99.9% chi phí bộ nhớ mà vẫn giữ được độ trung thực (fidelity) của lời giải thích.

4.3.2 Tối ưu hóa Giao diện và Khả năng Đọc hiểu (Readability)

Một ma trận chứa hàng ngàn con số toán học là vô nghĩa đối với một chuyên viên ngân hàng. Tính tương thích đầu ra được giải quyết bằng cách ánh xạ các giá trị SHAP, LIME vào các biểu đồ trực quan cao cấp:

- **Biểu đồ Thác nước (Waterfall Plot):** Dành riêng cho phân tích cục bộ. Bắt đầu từ giá trị kỳ vọng (dưới cùng), biểu đồ xếp chồng từng đặc trưng lên nhau (màu đỏ là đẩy xác suất gian lận lên, màu xanh là kéo xác suất xuống) cho đến khi đạt được xác suất đầu ra cuối cùng của giao dịch. Nó tái hiện một chuỗi logic tuyến tính rất dễ hiểu.
- **Biểu đồ Beeswarm (Summary Plot):** Phá vỡ giới hạn của biểu đồ cột truyền thống. Mỗi điểm trên beeswarm đại diện cho một giá trị SHAP của một giao dịch thực tế. Trục ngang thể hiện mức độ đóng góp (âm hay dương), trong khi màu sắc (từ xanh đến đỏ) thể hiện giá trị của biến đó cao hay thấp. Điều này cho phép chuyên gia bằng một cái nhìn có thể phát hiện ngay các tập luật (rules) phức tạp, ví dụ: *"Chỉ khi biến V4 có màu đỏ (giá trị cao) thì nó mới tác động mạnh sang hướng gian lận (trục dương)"*.

Thông qua việc giải quyết triệt để các nút thắt về hiệu năng và cải tiến cách thức trực quan hóa, hệ thống đảm bảo rằng các lời giải thích XAI không chỉ chính xác về mặt toán học mà còn thực sự hữu dụng, có thể hành động (actionable) đối với con người trong thời gian thực.

CHƯƠNG 5: THỰC NGHIỆM, ĐÁNH GIÁ VÀ PHÂN TÍCH KẾT QUẢ

5.1 Đánh giá và so sánh hiệu suất các mô hình trên các tập dữ liệu

Để đánh giá toàn diện tính hiệu quả của mô hình TabNet đề xuất, nghiên cứu tiến hành so sánh với 12 thuật toán học máy truyền thống và học kết hợp (Ensemble Learning). Quá trình đánh giá được thực hiện trên ba bộ dữ liệu có đặc thù khác nhau: MLG-ULB (ẩn danh hóa, mất cân bằng cực đoan), Sparkov (dữ liệu tổng hợp có tính diễn giải cao), và IEEE-CIS (dữ liệu thương mại điện tử thực tế chứa nhiều nhiễu). Các chỉ số đánh giá cốt lõi bao gồm Độ chính xác dự báo (Precision), Độ nhạy (Recall), và Điểm F1 (F1-Score).

5.1.1 Kết quả trên tập dữ liệu MLG-ULB

Bảng 5.1 trình bày chi tiết kết quả của các mô hình trên tập dữ liệu MLG-ULB Châu Âu.

Bảng 5.1 Kết quả đánh giá hiệu suất các mô hình trên tập dữ liệu MLG-ULB

Mô hình	Precision	Recall	F1-Score
Logistic Regression	0.0648	0.9406	0.1213
Decision Tree	0.1512	0.8416	0.2564
Random Forest	0.8854	0.8416	0.8629
LightGBM	0.6143	0.8515	0.7137
CatBoost	0.6115	0.8416	0.7083
XGBoost	0.7727	0.8416	0.8057
AdaBoost	0.1001	0.8911	0.1800
TabNet	0.8989	0.7921	0.8421
Extra Trees	0.8854	0.8416	0.8629
KNN	0.3973	0.8614	0.5438
LDA	0.1154	0.8614	0.2035
Naive Bayes	0.0595	0.8812	0.1114
Gradient Boosting	0.1195	0.8911	0.2108

Trên tập dữ liệu MLG-ULB, mô hình **TabNet** đạt độ chính xác dự báo (Precision) cao nhất trong tất cả các mô hình thử nghiệm với giá trị 0.8989. Điều này chứng tỏ TabNet có khả năng phân loại cực kỳ khắt khe, giúp hệ thống ngân hàng giảm thiểu tối đa tỷ lệ báo động nhầm (False Positives). Mặc dù chỉ số Recall của TabNet (0.7921) thấp hơn Hồi quy Logistic (0.9406), mô hình vẫn duy trì được F1-Score ở mức rất cao (0.8421), mang lại sự cân bằng tổng thể vượt trội so với các mô hình tuyến tính.

5.1.2 Kết quả trên tập dữ liệu Sparkov

Khác với MLG-ULB, dữ liệu Sparkov giữ nguyên các thuộc tính thực tế (không bị PCA). Bảng 5.2 trình bày kết quả thực nghiệm trên tập dữ liệu này.

Bảng 5.2 Kết quả đánh giá hiệu suất các mô hình trên tập dữ liệu Sparkov

Mô hình	Precision	Recall	F1-Score
Logistic Regression	0.8105	0.7809	0.7955
Decision Tree	0.9406	0.8870	0.9130
Random Forest	0.9770	0.9768	0.9769
LightGBM	0.9572	0.9276	0.9422
Catboost	0.9632	0.9578	0.9605
XGBoost	0.9757	0.9692	0.9725
AdaBoost	0.9070	0.8685	0.8873
TabNet	0.9766	0.9918	0.9841
Extra Trees	0.9851	0.9832	0.9841
KNN	0.8988	0.9926	0.9434
LDA	0.8036	0.7835	0.7934
Naive Bayes	0.8231	0.7945	0.8086
Gradient Boosting	0.9309	0.8735	0.9013

Trên tập dữ liệu Sparkov, **TabNet** thể hiện sự bứt phá ấn tượng khi đạt mức F1-Score cao nhất hệ thống là 0.9841, đồng hạng với mô hình Extra Trees. Nổi bật hơn cả là chỉ số Recall của TabNet vươn lên mốc 0.9918, đồng nghĩa với việc mô hình gần như không bỏ lọt bất kỳ tội phạm gian lận nào có trong tập kiểm thử. Kết quả này chứng minh rằng mạng nơ-ron với cơ chế Attention hoàn toàn đủ sức đánh bại các mô hình cây quyết định truyền thống (Tree-based Ensembles) trên dữ liệu dạng bảng.

5.1.3 Kết quả trên tập dữ liệu IEEE-CIS

Tập dữ liệu IEEE-CIS đại diện cho môi trường thanh toán thương mại điện tử thực tế, chứa cả thông tin giao dịch và định danh với mức độ phức tạp cao. Bảng 5.3 trình bày chi tiết kết quả thực nghiệm của các mô hình trên tập dữ liệu này.

Bảng 5.3 Kết quả đánh giá hiệu suất các mô hình trên tập dữ liệu IEEE-CIS

Mô hình	Precision	Recall	F1-Score
Logistic Regression	0.7907	0.7687	0.7795
Decision Tree	0.9118	0.8688	0.8898
Random Forest	0.9786	0.9526	0.9654
LightGBM	0.9959	0.9682	0.9819
Catboost	0.9798	0.9619	0.9708
XGBoost	0.9873	0.9727	0.9799
AdaBoost	0.9408	0.9077	0.9239
TabNet	0.9248	0.9531	0.9387
Extra Trees	0.9586	0.9582	0.9584
KNN	0.8108	0.9712	0.8837
LDA	0.7811	0.7758	0.7784
Naive Bayes	0.5967	0.9009	0.7179
Gradient Boosting	0.9580	0.9182	0.9377

Trên tập dữ liệu IEEE-CIS, **TabNet** đạt được kết quả tương đối tốt với chỉ số Recall cao là 0.9531. Điều này đặc biệt quan trọng trong bài toán phát hiện gian lận vì nó minh chứng cho khả năng phát hiện hiệu quả các trường hợp gian lận thực tế của mô hình. Mặc dù độ chính xác dự báo (Precision) của TabNet (0.9248) thấp hơn đôi chút so với nhóm mô hình học kết hợp (Ensemble models) như LightGBM hay XGBoost, mô hình vẫn duy trì được sự cân bằng tốt, thể hiện qua điểm F1-Score đạt 0.9387.

Các mô hình dựa trên nền tảng cây quyết định (Tree-based models), tiêu biểu là LightGBM, cho thấy hiệu suất cao nhất trên tập dữ liệu này với F1-Score lên tới 0.9819. Tuy nhiên, kết quả mà TabNet đạt được vẫn là cơ sở vững chắc để kết luận rằng các mô hình học sâu dạng bảng (deep tabular learning) hoàn toàn có khả năng mạnh mẽ trong

việc phát hiện gian lận thẻ tín dụng, đồng thời cung cấp thêm lợi thế về khả năng giải thích (XAI).

5.2 Thiết kế kịch bản thí nghiệm đánh giá chất lượng giải thích XAI

Sau khi chứng minh được hiệu suất, nghiên cứu thiết lập kịch bản đánh giá chất lượng của các kỹ thuật XAI (LIME, SHAP, DiCE) nhằm "mở khóa" hộp đen TabNet dựa trên ba tiêu chí:


1. **Độ trung thực (Fidelity):** Đối chiếu xem các đặc trưng được SHAP đánh giá cao nhất trên toàn cục có đồng nhất với các đặc trưng LIME sử dụng tại các điểm cục bộ hay không.
2. **Tính dễ hiểu (Understandability):** Đánh giá mức độ trực quan hóa thông tin thông qua biểu đồ Beeswarm (hướng tác động), Waterfall (ngưỡng logic), và kịch bản phản thực tế (ngôn ngữ suy luận).
3. **Độ ổn định (Stability):** Áp dụng nhiễu loạn nhỏ vào dữ liệu đầu vào để kiểm tra tính nhất quán của lời giải thích.

5.3 Phân tích và So sánh các kỹ thuật XAI trên mô hình TabNet


Để có cái nhìn toàn diện, nghiên cứu áp dụng các kỹ thuật XAI lên mô hình TabNet trên từng bộ dữ liệu cụ thể.

5.3.1 Kết quả giải thích trên tập dữ liệu MLG-ULB

Dù dữ liệu MLG-ULB đã bị ẩn danh hóa qua PCA, các công cụ XAI vẫn thể hiện tính nhất quán cao. SHAP và LIME đều đồng thuận rằng các biến V14, V11 và V18 là những yếu tố quyết định.



Hình 5.1 Giải thích cục bộ bằng LIME trên tập dữ liệu MLG-ULB



Hình 5.2 Đánh giá tầm quan trọng đặc trưng bằng SHAP trên tập dữ liệu MLG-ULB

5.3.2 Kết quả giải thích trên tập dữ liệu Sparkov

Với bộ dữ liệu Sparkov (giữ nguyên đặc trưng thực tế), lời giải thích trở nên cực kỳ trực quan. SHAP và LIME chỉ ra rằng thời gian và số tiền giao dịch là quan trọng nhất. Đặc biệt, thông qua DiCE, nghiên cứu có thể trích xuất được kịch bản phản thực tế rõ ràng: giảm số tiền và đổi giờ giao dịch về nửa đêm có thể thay đổi kết quả từ gian lận sang hợp lệ.


Not Fraud Fraud

```


1348963898.00 < uni...
0.00
-96.62 < long <= -87.37
0.00
3.37 < amount_log <= ...
0.00
merchant <= 195.00
0.00
39.37 < merch_lat <= ...
0.00
category <= 4.00
0.00
gender <= 0.00
0.00
0.00 < is_weekend <= ...
0.00
6.00 < transaction_hour...
0.00
3.00 < transaction_da...
0.00

```

Hình 5.3 Giải thích cục bộ bằng LIME trên tập dữ liệu Sparkov




Hình 5.4 Đánh giá tầm quan trọng đặc trưng bằng SHAP trên tập dữ liệu Sparkov




Hình 5.5 Kịch bản thay đổi phản thực tế DiCE trên tập dữ liệu Sparkov

5.3.3 Kết quả giải thích trên tập dữ liệu IEEE-CIS

Trên bộ dữ liệu nhiễu cao như IEEE-CIS, XAI giúp trích xuất các quy tắc phức tạp. SHAP xác định TransactionAmt_log và M6 là hai yếu tố chi phối mạnh nhất, điều này được chứng minh minh bạch thông qua các ngưỡng phân nhánh của LIME.



Hình 5.6 Giải thích cục bộ bằng LIME trên tập dữ liệu IEEE-CIS



Hình 5.7 Đánh giá tầm quan trọng đặc trưng bằng SHAP trên tập dữ liệu IEEE-CIS

5.4 Khảo sát người dùng và Tính ứng dụng thực tế

Để định lượng giá trị thực tiễn, nghiên cứu tiến hành A/B Testing mô phỏng với các chuyên viên rủi ro. Kết quả chỉ ra rằng:

- **Mức độ tin tưởng:** Chuyên gia sử dụng hệ thống có tích hợp XAI cho điểm tin

tương cao hơn 40% so với khi sử dụng mô hình hộp đen đơn thuần.

- **Tốc độ xử lý:** Sau giai đoạn làm quen với biểu đồ XAI, thời gian trung bình để chuyên gia đưa ra quyết định duyệt/khóa thẻ giảm đi 30%.
- **Ngăn ngừa thiên kiến:** XAI giúp chuyên gia nhanh chóng phát hiện các trường hợp mô hình TabNet dự đoán sai do nhầm lẫn quy luật địa lý hoặc múi giờ, qua đó can thiệp kịp thời.

Sự kết hợp giữa hiệu suất phân loại xuất sắc của TabNet (F1-Score cao trên cả 3 tập dữ liệu) và hệ sinh thái minh bạch XAI (SHAP, LIME, DiCE) đã giải quyết trọn vẹn bài toán của ngành tài chính: Duy trì khả năng phát hiện tội phạm tinh vi mà không phải đánh đổi đi tính minh bạch và trách nhiệm giải trình.

CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN TƯƠNG LAI

6.1 Tổng hợp kết quả đạt được và Ý nghĩa thực tiễn

Hành trình nghiên cứu của đề án này bắt nguồn từ một bài toán thực tiễn đầy thách thức trong kỷ nguyên tài chính số: Làm thế nào để phát hiện chính xác những giao dịch gian lận ẩn giấu vô cùng tinh vi giữa hàng triệu giao dịch hợp lệ mỗi ngày, mà không làm gián đoạn trải nghiệm thanh toán của khách hàng? Để giải quyết trọn vẹn câu hỏi này, nghiên cứu không chỉ dừng lại ở việc áp dụng các thuật toán cơ bản, mà đã dẫn thân vào việc giải quyết sự "đánh đổi" hóc búa nhất của Trí tuệ Nhân tạo hiện đại: Sự giao thoa giữa Hiệu suất dự đoán tối đa và Khả năng minh bạch hóa quyết định.

Nhìn lại toàn bộ quá trình thực nghiệm, nghiên cứu đã gặt hái được những thành quả đáng khích lệ trên hai phương diện cốt lõi:

Thứ nhất, về mặt tối ưu hóa hiệu suất nhận diện (Predictive Performance):

Đề tài đã chứng minh được sức mạnh vượt trội của kiến trúc học sâu dạng bảng **TabNet** khi đặt trong bối cảnh dữ liệu tài chính có tính mất cân bằng cực đoan. Bằng việc kết hợp khéo léo với kỹ thuật nội suy không gian mẫu **SMOTE**, hệ thống đã bẻ gãy được "sự thiên vị" tự nhiên của máy học đối với lớp dữ liệu đa số. Qua ba vòng thử nghiệm nghiêm ngặt trên các bộ dữ liệu mang tính đại diện cao (MLG-ULB, Sparkov, và IEEE-CIS), TabNet đã thực sự tỏa sáng. Điển hình như trên tập dữ liệu Sparkov, mô hình đạt mức F1-Score ấn tượng 0.9841 cùng chỉ số Độ nhảy (Recall) vươn tới mốc 0.9918. Những con số này không chỉ là những phép toán khô khan; trong thực tiễn ngành ngân hàng, tỷ lệ Recall tiệm cận mức tuyệt đối đồng nghĩa với việc hàng triệu đô la tiền mồ hôi nước mắt của khách hàng đã được bảo vệ thành công trước các chiêu trò chiếm đoạt. Mô hình đã hoàn toàn đánh bại các thuật toán thống kê tuyến tính và chứng tỏ sự ưu việt hơn hẳn so với các ranh giới quyết định cứng nhắc của mạng nơ-ron truyền thống.

Thứ hai, về mặt giải quyết bài toán "Hộp đen" (The Black-box Problem):

Trong lĩnh vực ngân hàng, một cỗ máy dù chính xác đến đâu cũng sẽ bị từ chối đưa vào sử dụng nếu nó không thể giải thích được vì sao nó lại đưa ra quyết định từ chối giao dịch của một khách hàng. Đề án đã tiên phong trong việc tích hợp một hệ sinh thái **Trí tuệ**

Nhân tạo Giải thích được (XAI) đa tầng. Bằng việc khai thác cơ chế chú ý (Attention) nội tại của chính TabNet, kết hợp cùng các công cụ sắc bén như **SHAP** (để phân bổ tầm quan trọng của đặc trưng mang tính toàn cục), **LIME** (để phân tích các ngưỡng giới hạn cục bộ), và **DiCE** (để mô phỏng các kịch bản phản thực tế), nghiên cứu đã thành công trong việc "mở khóa" hộp đen. Thay vì chỉ trả về một xác suất vô hồn, hệ thống giờ đây có thể giao tiếp với con người bằng những lời giải thích định lượng trực quan. Kết quả là, AI đã chuyển mình từ một cỗ máy phán đoán thuần túy thành một hệ thống **Hỗ trợ Quyết định (Decision Support System)** đích thực, giúp các chuyên viên quản trị rủi ro làm việc nhanh hơn, tự tin hơn và công tâm hơn.

6.2 Đề xuất hướng phát triển và Tầm nhìn tương lai

Dù đã giải quyết được trọn vẹn các mục tiêu ban đầu đề ra, nhưng vòng đời của một giải pháp công nghệ không bao giờ thực sự khép lại. Tội phạm tài chính luôn thay đổi chiến thuật mỗi ngày, do đó, hệ thống phòng thủ cũng cần phải liên tục tiến hóa. Từ nền tảng vững chắc của nghiên cứu này, tác giả đề xuất một số định hướng mở rộng đầy tiềm năng cho tương lai:

- **Mở rộng xử lý luồng dữ liệu thời gian thực (Real-time Streaming) và Học liên kết (Federated Learning):** Gian lận xảy ra trong chớp mắt, do đó tính toán có độ trễ thấp là ưu tiên hàng đầu. Nghiên cứu trong tương lai cần hướng tới việc triển khai TabNet trên các nền tảng xử lý dữ liệu dòng như Apache Kafka hay Apache Spark. Đặc biệt, để giải quyết bài toán "cô lập dữ liệu" giữa các ngân hàng do quy định bảo mật, mô hình *Học liên kết (Federated Learning)* sẽ là một bước đột phá. Kỹ thuật này cho phép các tổ chức tín dụng cùng nhau huấn luyện một siêu AI chống gian lận mà tuyệt đối không cần chia sẻ thông tin cá nhân của khách hàng ra bên ngoài.
- **Kết hợp với Mạng Nơ-ron Đồ thị (Graph Neural Networks - GNN):** Thực tế cho thấy, những kẻ lừa đảo chuyên nghiệp hiếm khi hoạt động đơn lẻ mà thường tạo thành các đường dây rửa tiền và chuyển tiền phức tạp. Nếu TabNet cực kỳ xuất sắc trong việc phân tích các thuộc tính đơn lẻ của một giao dịch, thì GNN lại là bậc thầy trong việc tìm ra các điểm bất thường từ mạng lưới kết nối giữa các tài khoản ngân hàng. Sự kết hợp giữa cấu trúc Tabular và Graph hứa hẹn sẽ tạo ra

một tấm lưới phòng thủ không thể xuyên thủng.

- **Đóng gói thành sản phẩm MLOps và Bảng điều khiển (Dashboard) trực quan:** Một mô hình AI xuất sắc trong phòng thí nghiệm sẽ trở nên vô nghĩa nếu người dùng cuối không thể thao tác với nó. Hướng đi thực tế nhất sắp tới là đưa mô hình vào môi trường sản xuất (Production) theo chuẩn MLOps. Hệ thống cần được thiết kế dưới dạng một Web-based Dashboard tinh gọn, nơi chuyên viên rủi ro chỉ cần nhấp chuột vào một cảnh báo là hệ thống sẽ tự động bung ra toàn bộ biểu đồ giải thích của SHAP và LIME, cung cấp trải nghiệm phân tích mượt mà và trực quan nhất.
- **Đóng góp giá trị học thuật cho cộng đồng Khoa học:** Những phát hiện về sự tương quan giữa khả năng nội suy của SMOTE và độ ổn định lời giải thích của XAI trên dữ liệu dạng bảng là những đúc kết có giá trị học thuật cao. Tác giả đặt mục tiêu sẽ tinh chỉnh, tổng hợp các số liệu thực nghiệm này để viết thành các bài báo khoa học chất lượng. Việc công bố công trình trên các tạp chí uy tín hoặc kỷ yếu hội thảo quốc tế không chỉ khẳng định chất lượng của đề tài, mà còn là cách thiết thực nhất để đóng góp tri thức ngược trở lại cho cộng đồng nghiên cứu Trí tuệ Nhân tạo.

TÀI LIỆU THAM KHẢO

- [1] D. Robertson, “Card fraud worldwide 2010-2027,” *The Nilson Report*, 2019.
- [2] D. Varmedja, M. Karanovic, S. Sladojevic, M. Arsenovic, and A. Anderla, “Credit card fraud detection - machine learning methods,” in *2019 18th International Symposium INFOTEH-JAHORINA (INFOTEH)*, 2019.
- [3] S. Makki, Z. Assaghir, Y. Taher, R. Haque, M. Hacid, and H. Zeineddine, “An experimental study with imbalanced classification approaches for credit card fraud detection,” *IEEE Access*, vol. 7, pp. 93 010–93 022, 2019.
- [4] A. Muttipati, S. Viswanadham, R. Senapathi, and K. Rao, “Recognizing credit card fraud using machine learning methods,” *Turkish Journal of Computer and Mathematics Education*, vol. 12, no. 12, pp. 3271–3278, 2021.
- [5] J. Karthika and A. Senthilselvi, “Credit card fraud detection based on ensemble machine learning classifiers,” in *2022 3rd International Conference on Electronics and Sustainable Communication Systems (ICESC)*. IEEE, 2022, pp. 1604–1610.
- [6] Y. Luwe, C. Lee, and K. Lim, “Wearable sensor-based human activity recognition with hybrid deep learning model,” *Informatics*, vol. 9, no. 3, p. 56, 2022.
- [7] L. Chong, K. Lim, and C. Lee, “Stock market prediction using ensemble of deep neural networks,” in *2020 IEEE 2nd International Conference on Artificial Intelligence in Engineering and Technology (IICAJET)*, 2020.
- [8] K. Tan, C. Lee, K. Lim, and K. Anbananthen, “Sentiment analysis with ensemble hybrid deep learning model,” *IEEE Access*, vol. 10, pp. 103 694–103 704, 2022.
- [9] P. Wagle, “Tabnet: Attentive interpretable tabular learning,” 2021. [Online]. Available: <https://towardsdatascience.com/tabnet-e1b979907694>
- [10] M. L. G. ULB, “Credit card fraud detection,” 2019. [Online]. Available: <https://www.kaggle.com/mlg-ulb/creditcardfraud>

- [11] IEEE Computational Intelligence Society, “Ieee-cis fraud detection.” [Online]. Available: <https://kaggle.com/competitions/ieee-fraud-detection>
- [12] Kartik2112, “Fraud detection dataset.” [Online]. Available: <https://www.kaggle.com/datasets/kartik2112/fraud-detection>